

Data Understanding Report

Dataset Penjualan Video Game (Global Sales)

1. Nama Dataset

DataSaleGame.xlsx (Global Video Game Sales Dataset)

2. Sumber

Dataset diperoleh dari platform Kaggle (kaggle.com) dalam format file spreadsheet (.xlsx) berisi data penjualan video game secara global. Data mencakup judul game, tahun rilis, genre, publisher, serta angka penjualan di berbagai wilayah (Amerika Utara, Eropa, Jepang, dan wilayah lainnya).

3. Deskripsi

Dataset ini berisi rekapitulasi penjualan video game (dalam satuan juta unit) yang dirilis pada periode tahun 2013 hingga 2020. Setiap baris data merepresentasikan satu judul game beserta informasi peringkat penjualan (Pos), genre, publisher, dan rincian penjualan per wilayah geografis, ditutup dengan total penjualan global.

4. Tujuan Dataset

Dataset ini bertujuan untuk menganalisis performa penjualan video game secara global guna mengidentifikasi tren pasar, genre yang paling diminati, publisher dengan performa penjualan terbaik, serta perbandingan preferensi pasar antar wilayah (Amerika Utara, Eropa, Jepang, dan wilayah lainnya).

5. Jumlah Data

Dataset terdiri dari 613 baris data (records), masing-masing merepresentasikan satu judul video game.

6. Jumlah Variabel

Dataset memiliki 10 variabel (kolom) sebagai berikut:

No	Nama Variabel	Tipe Data	Keterangan
1	Pos	Numerik (int)	Peringkat/posisi penjualan game
2	Game	Teks	Judul video game
3	Year	Numerik (float)	Tahun rilis game (terdapat 108 nilai kosong)
4	Genre	Teks (kategorikal)	Genre/kategori game (16 kategori unik)
5	Publisher	Teks (kategorikal)	Perusahaan penerbit game (98 publisher unik, 108 nilai kosong)
6	North America	Numerik (float)	Penjualan di wilayah Amerika Utara (juta unit)
7	Europe	Numerik (float)	Penjualan di wilayah Eropa (juta unit)
8	Japan	Numerik (float)	Penjualan di wilayah Jepang (juta unit)
9	Rest of World	Numerik (float)	Penjualan di wilayah lainnya (juta unit)
10	Global;	Teks/numerik	Total penjualan global (juta unit); perlu dibersihkan dari karakter ';'.

7. Target Analisis

- Total/rata-rata penjualan global (kolom Global;) sebagai variabel target utama untuk analisis performa.
- Genre dan Publisher sebagai variabel kategorikal untuk analisis tren dan segmentasi pasar.
- Perbandingan penjualan antar wilayah (North America, Europe, Japan, Rest of World) untuk analisis preferensi regional.

8. Potensi Insight

- Genre Action mendominasi jumlah judul yang dirilis (147 judul), diikuti Shooter (70) dan Sports (60), mengindikasikan genre paling produktif di pasar.
- Publisher dengan jumlah judul terbanyak adalah Ubisoft (45 judul), Microsoft Studios (31), dan Activision (29), yang dapat dianalisis lebih lanjut terhadap kontribusi penjualannya.
- Rentang tahun rilis 2013–2020 memungkinkan analisis tren penjualan game dari tahun ke tahun.
- Distribusi penjualan global sangat timpang (rata-rata 0,44 juta unit, median hanya 0,06 juta, maksimum 8,72 juta), menunjukkan sebagian kecil judul (blockbuster) mendominasi total penjualan.
- Perbandingan penjualan antar wilayah dapat mengungkap perbedaan selera pasar, misalnya dominasi tertentu di Amerika Utara dibanding Jepang.

9. Kelebihan Dataset

- Struktur data rapi dan konsisten dalam format tabel dengan header kolom yang jelas.
- Mencakup dimensi geografis yang lengkap (4 wilayah penjualan) sehingga mendukung analisis komparatif regional.
- Ukuran dataset (613 baris) cukup ringkas untuk diolah dan dianalisis tanpa memerlukan sumber daya komputasi besar.
- Tersedia variabel kategorikal (Genre, Publisher) yang kaya untuk analisis segmentasi dan tren pasar.

10. Kekurangan Dataset

- Terdapat nilai kosong (missing value) pada kolom Year dan Publisher, masing-masing sebanyak 108 baris (sekitar 17,6% dari total data).
- Kolom Global; masih berupa teks dengan tanda titik koma (;) sehingga perlu proses pembersihan (data cleaning) sebelum dapat dianalisis secara numerik.
- Terdapat 1 kemungkinan data duplikat pada kolom Game yang perlu diverifikasi lebih lanjut.
- Tidak terdapat kolom platform (misalnya PS4, Xbox, PC) maupun rating/skor game, sehingga analisis platform dan kualitas game tidak dapat dilakukan.
- Cakupan tahun terbatas (2013–2020) sehingga kurang representatif untuk analisis tren jangka panjang.