

Data Cleaning & Preparation

Persentase Penduduk Miskin (P0) Menurut Provinsi & Daerah 2025

 Abryan Yoga Pratama | Junior Data Analyst

Gambaran Dataset & Audit Awal

Identifikasi Dataset Raw

- **Sumber Data:** Laporan BPS Susenas Maret 2025 mengenai Persentase Penduduk Miskin (PO).
- **Cakupan Wilayah:** 38 Provinsi di Indonesia (Perkotaan, Perdesaan, dan Total).
- **Tujuan Audit:** Menilai tingkat kelayakan data sebelum diolah oleh tim Senior Data Analyst.
- **Fokus Evaluasi:** Deteksi missing value, tipe data inkonsisten, duplikasi baris, serta penulisan header yang berantakan.



Permasalahan Data yang Ditemukan

Kategori Audit	Permasalahan Ditemukan	Dampak Analisis	Solusi Perbaikan
Tipe Data	Angka persentase dibaca sebagai string / text dengan karakter -	Gagal kalkulasi agregasi & grafik EDA	Konversi ke format float64
Penamaan Kolom	Nama kolom menggunakan spasi ganda & kapitalisasi tidak konsisten	Kesulitan pemanggilan variabel pada Pandas/SQL	Standardisasi penamaan (snake_case)
Missing Value	Terdapat sel kosong pada sampel agregat wilayah perdesaan	Metrik agregat nasional tidak presisi	Imputasi menggunakan nilai median daerah
Duplikasi Baris	Header tabel berulang akibat ekspor PDF/CSV	Total provinsi membengkak & data terdistorsi	Pembersihan baris duplikat (drop_duplicates)

Tahapan & Metodologi Cleaning



1. Restrukturisasi

Menghapus header sekunder berulang, trim whitespace pada nama provinsi, serta merapikan struktur indeks tabel.



2. Pembersihan Data

Mengubah karakter khusus/dash menjadi NaN, imputasi data kosong, dan mengonversi kolom menjadi numerik presisi.



3. Feature Engineering

Membuat variabel derivatif baru (Disparitas Kota-Desa, Klasifikasi Kemiskinan, dan Flag Nasional) untuk analisis mendalam.

Log Clean Up & Transformasi Data

Item Evaluasi	Metode Pandas / Solusi	Kondisi Sebelum Cleaning	Kondisi Setelah Cleaning
Header Kolom	df.rename(columns=...)	'Perkotaan ', 'Perdesaan'	'Perkotaan_PO', 'Perdesaan_PO'
Tipe Data Numeric	pd.to_numeric()	object (misal: '8.54')	float64 (misal: 8.54)
Spasi Teks	str.strip()	'ACEH '	'Aceh'
Duplikasi Baris	df.drop_duplicates()	40 Baris (Terdapat header terulang)	38 Baris Unik (Sesuai 38 Provinsi)

Feature Engineering Tambahan

1. Disparitas Kota-Desa (Selisih_PO)

Rumus: $\text{Perdesaan_PO} - \text{Perkotaan_PO}$

Fitur ini dibuat untuk mengukur sejauh mana ketimpangan persentase kemiskinan antara wilayah perdesaan dan perkotaan di setiap provinsi secara langsung.

2. Kategori & Flag Rata-Rata Nasional

Variabel Baru: Kategori_Kemiskinan & Di_Atas_Rata2_Nasional

Mengelompokkan provinsi ke dalam kategori (Rendah <6%, Sedang 6-10%, Tinggi >10%) serta menandai apakah angka PO berada di atas rata-rata nasional (8.47%).

Ringkasan Dataset Final Clean

38

Provinsi Terverifikasi

Kualitas Data Final 100% Valid


Cakupan Total: 38 Baris unik mewakili seluruh provinsi Indonesia tanpa duplikasi.

P0 Nasional (Maret 2025): 8.47% (Perkotaan: 6.73% | Perdesaan: 11.03%).

Rentang Kemiskinan: Terendah 3.72% (Bali) hingga Tertinggi 30.03% (Papua Pegunungan).

Integritas Data: 0 Missing Value, 0 Duplicate, seluruh tipe data terekam presisi.

Profil Kemiskinan Terendah vs Tertinggi



Insight Grafik: Terdapat gap signifikan hingga 8x lipat antara provinsi dengan persentase kemiskinan terendah (Bali 3.72%) dan tertinggi (Papua Pegunungan 30.03%).

Insight Utama Hasil Cleaning



Ketimpangan Perdesaan Tinggi: Secara nasional, persentase kemiskinan perdesaan (11.03%) jauh lebih tinggi daripada perkotaan (6.73%), dengan selisih terbesar ditemukan di provinsi wilayah Timur.



Konsentrasi Wilayah Kategori Tinggi: Mayoritas provinsi di Pulau Papua dan Nusa Tenggara masuk ke dalam *Kategori Kemiskinan Tinggi* (>10%).



Performa Wilayah Terbaik: Bali (3.72%), Kalimantan Selatan (3.84%), dan DKI Jakarta (4.28%) mencatatkan angka kemiskinan terendah nasional.



Dataset Ready for EDA: File Final_Clean_Dataset.xlsx telah bersih sepenuhnya dan siap diserahkan untuk analisis eksploratif (EDA) Minggu 4.